

PROJETO DE EVOLUÇÃO

Agente de Atendimento + Assistente Inteligente

Escopo executivo e técnico · prioridades · cronograma · critérios de aceite

Versão 1.0

Planejamento acelerado: 10 semanas · execução com Claude Code · entregas incrementais

05 de agosto de 2026

1. Resumo executivo

Este projeto transforma o produto atual em uma plataforma com duas inteligências integradas: um agente que atende pacientes e clientes e um assistente inteligente que ajuda o profissional a administrar o negócio. A estratégia não é competir apenas por respostas com IA; é resolver a rotina operacional, organizar decisões e demonstrar resultado.

Tese do produto

O agente deve resolver, não apenas responder. O assistente deve analisar, recomendar e executar com autorização. Ambos compartilham dados confiáveis, políticas e auditoria.

Objetivos do programa

- Eliminar as principais fontes de erros intermitentes: duplicidade, mensagens fora de ordem, conflitos de agenda, falhas silenciosas e divergência com calendários externos.
- Criar uma experiência diferenciada: memória útil, fila de espera, recorrência, central de pendências, transferência com resumo e autonomia progressiva.
- Entregar um assistente do profissional capaz de responder perguntas sobre o negócio, produzir briefings, identificar riscos e executar comandos autorizados.
- Demonstrar valor financeiro: faltas evitadas, vagas recuperadas, tempo poupado, cobranças acompanhadas e receita preservada.
- Preparar o SaaS para crescer com segurança, observabilidade, testes e arquitetura compatível com múltiplos clientes.

Marcos previstos

Marco	Prazo	Resultado esperado
M1 - Operação estabilizada	Semana 3	Conversas ordenadas, agenda protegida, erros rastreáveis e fluxo crítico testado.
M2 - Assistente inteligente	Semana 4	Consultas em linguagem natural, briefing, ações com aprovação e handoff.
M3 - Diferenciação operacional	Semana 6	Fila de espera, recorrência, memória e central de pendências.
M4 - Produto orientado a resultado	Semana 7	Prevenção de faltas, recomendações e métricas financeiras.
M5 - V1 validada	Semana 10	Segurança, piloto, documentação e operação comercial padronizada.

Premissa de planejamento

Cronograma estimado para um desenvolvedor principal usando Claude Code de forma intensiva, com validação semanal do responsável pelo produto e acesso a um cliente-piloto. A IA acelera implementação, testes, refatoração e documentação. Observação em produção, validação humana e janela de piloto não devem ser eliminadas, pois protegem agenda, pagamentos e experiência de clientes reais.

2. Situação atual e decisão inicial

O produto já possui agenda, confirmação, remarcação, cancelamento, cobrança, contratos, áudio, imagem, dashboard, integrações e rotinas administrativas. Isso é uma vantagem relevante: o projeto parte de uma base funcional e de uso real, não de uma ideia inicial.

Atenção antes de desenvolver

A documentação descreve a versão avançada de aproximadamente 1.706 linhas no agente, enquanto a área de trabalho aberta contém uma versão antiga de aproximadamente 190 linhas. A primeira atividade obrigatória é definir a branch canônica, confirmar a build realmente implantada e impedir que melhorias sejam feitas sobre uma cópia desatualizada.

Forças atuais

- Produto multi-tenant já em uso e com cliente real.
- Conhecimento acumulado sobre psicologia e outros negócios com agenda.
- Ações determinísticas para fluxos críticos e proteções contra algumas alucinações.
- Cobrança, contratos e calendário dentro do mesmo produto.
- Dashboard administrativo e dados suficientes para evoluir para inteligência operacional.

Fragilidades prioritárias

Risco	Efeito percebido	Tratamento planejado
Mensagem atual duplicada no contexto	IA interpreta repetição e responde fora de contexto	Correção do histórico e teste automatizado.
Mensagens paralelas do mesmo telefone	Respostas fora de ordem e ações concorrentes	Fila por tenant+telefone e agrupamento curto.
Reserva não atômica	Dois clientes podem disputar o mesmo horário	Transação e proteção no banco.
Slots atravessam dias pela duração	Horários com minutos estranhos ou fora do expediente	Gerador diário determinístico.
IA síncrona no fluxo principal	Lentidão, timeout e retries	Worker/fila e limites de tempo.
Jobs dentro da aplicação	Duplicidade em deploy ou múltiplas réplicas	Reserva idempotente e worker dedicado.
Calendário externo sem reconciliação	Sistema e Google/CalDAV divergem	Outbox, retry e status de sincronização.
SQLite sob concorrência crescente	Locks e falhas intermitentes	WAL no curto prazo e migração planejada.

Princípios de execução

- Não ampliar funcionalidades antes de estabilizar os fluxos que alteram agenda, contrato e pagamento.
- Toda ação crítica deve ser validada pelo código, idempotente, auditável e testável.
- Entregas pequenas em piloto; ativação gradual por tenant e por funcionalidade.
- A IA interpreta e redige; o sistema determina o que é verdade e o que foi executado.

3. Arquitetura de produto desejada

O desenho-alvo separa conversação de execução. Essa separação reduz alucinações e permite trocar modelos de IA sem comprometer a agenda ou o financeiro.

Camada	Responsabilidade	Exemplo
Entrada e fila	Normalizar, deduplicar, agrupar e ordenar mensagens	Três mensagens curtas viram uma única interação.
Estado da conversa	Registrar intenção, dados coletados, pendências e próximo passo	Aguardando escolha de horário; não pede nome novamente.
IA de compreensão	Classificar intenção e extrair informações com confiança	Data desejada, período, serviço, motivo de handoff.
Motor de políticas	Decidir o que pode ser feito e quando exige humano	Pagamento nunca é confirmado apenas por imagem.
Ferramentas operacionais	Consultar/reservar agenda, contrato, cobrança e calendário	Reserva atômica usando token de slot.
IA de redação	Produzir mensagem natural usando apenas dados validados	Confirma o horário retornado pela agenda.
Entrega e outbox	Enviar, repetir com segurança e registrar entrega	Mensagem com status pendente, enviada ou falhou.
Auditoria e qualidade	Explicar decisões, medir erros e criar regressões	Correção do cliente vira teste permanente.

Contrato estruturado de decisão

A resposta interna da IA deve conter intenção, confiança, dados coletados, dados faltantes, operação solicitada e necessidade de handoff. Ela não deve afirmar que uma consulta foi marcada antes da ferramenta confirmar. Horários devem ser selecionados por token temporário, não por índice numérico frágil.

Regra de ouro

Uma mensagem elegante nunca pode esconder uma operação que falhou. Primeiro o sistema executa e confirma; depois a IA comunica.

Estados mínimos da conversa

Estado	Entrada esperada	Saída segura
Identificação	Nome ou reconhecimento pelo telefone	Cliente identificado ou handoff.
Coleta de preferência	Dia, período, serviço ou profissional	Consulta de agenda filtrada.
Oferta de horários	Escolha entre tokens válidos	Reserva temporária/validação.
Confirmação da ação	Aceite explícito quando necessário	Criação ou remarcação atômica.
Pendência humana	Assunto sensível, negociação ou baixa confiança	Resumo e transferência.
Concluído	Operação confirmada	Mensagem final + próximo lembrete.

4. Produto com duas inteligências integradas

A experiência será dividida por público e responsabilidade. O Agente de Atendimento conversa com pacientes e clientes. O Assistente Inteligente conversa com o profissional, interpreta os dados do negócio e o ajuda a decidir e agir. Eles compartilham a mesma fonte de verdade, mas usam permissões, políticas e prompts separados.

Dimensão	Agente de Atendimento	Assistente Inteligente
Usuário	Paciente ou cliente no WhatsApp	Profissional, gestor ou equipe autorizada
Missão	Atender, orientar e concluir jornadas	Organizar, analisar, recomendar e executar
Exemplos	Agendar, remarcar, confirmar, cancelar, contrato e cobrança	Briefing, pendências, ocupação, previsão, bloqueios e ações
Autonomia	Definida por fluxo e risco	Consulta livre; alterações com política de aprovação
Memória	Preferências e contexto do relacionamento	Preferências operacionais e decisões do profissional
Saída segura	Mensagem baseada em operação confirmada	Resposta com evidência, recomendação e impacto

Capacidades do Assistente Inteligente

Capacidade	Exemplos de uso
Perguntas sobre o negócio	Como está minha agenda amanhã? Quem ainda não confirmou? Quanto tenho previsto para receber?
Briefing proativo	Atendimentos do dia, riscos, vagas, pagamentos, contratos e conversas aguardando humano.
Recomendações	Preencher uma vaga, contatar paciente sem retorno, abrir faixa extra ou revisar aumento de faltas.
Comandos operacionais	Bloquear período, preparar mensagens, oferecer vaga, pausar agente e criar lembrete.
Aprovação inteligente	Executar consultas automaticamente; pedir confirmação para envio, alteração de agenda ou ação financeira.
Explicação	Mostrar dados usados, regra aplicada, impacto previsto e resultado da execução.
Resumo de handoff	Entregar ao profissional contexto, intenção, tentativas anteriores e decisão necessária.

Exemplos de interação

- 'Quais pacientes estão sem próxima sessão e costumavam vir semanalmente?'
- 'Bloqueie sexta à tarde. Antes de avisar os pacientes afetados, mostre a mensagem para eu aprovar.'
- 'Encontrei uma vaga amanhã às 17h. Quem da fila é compatível e quanto de receita podemos recuperar?'
- 'Faça um fechamento do dia e separe apenas o que precisa da minha decisão.'

Diferencial central

Um agente cuida dos clientes; um assistente ajuda o profissional a cuidar do negócio. A integração entre os dois transforma conversas em operação, decisão e resultado.

5. Cronograma mestre - 10 semanas

As fases são sequenciais onde existe dependência crítica, mas pesquisa, design e preparação de testes podem ocorrer em paralelo. Cada marco deve ser colocado em produção apenas após piloto e validação dos critérios de aceite.

Frente	1	2-3	4	5-6	7	8	9-10
F0 Alinhamento	•						
F1 Confiabilidade	•	•					
F2 Qualidade/controle			•				
F3 Diferenciação				•			
F4 Inteligência					•		
F5 Escala/segurança						•	
F6 Rollout							•

Semanas	Fase	Entrega de negócio
1	F0 - Alinhamento	Versão canônica, baseline, métricas e plano de rollout.
2-3	F1 - Confiabilidade	Fluxos críticos ordenados, atômicos e observáveis.
4	F2 - Assistente e controle	Assistente inteligente, autonomia, handoff e aprendizado.
5-6	F3 - Diferenciação	Espera, recorrência, memória e central de pendências.
7	F4 - Inteligência	Prevenção, recomendações e resultado financeiro mensurável.
8	F5 - Escala	Banco/filas/segurança/onboarding e operação preparada para crescimento.
9-10	F6 - Rollout	Piloto ampliado, documentação, treinamento e lançamento da V1.

Cadência recomendada

- Segunda: planejamento e escolha das histórias da semana.
- Quarta: demonstração interna com conversas sintéticas e regressões.
- Sexta: piloto controlado, revisão de métricas, erros e decisão de liberação.
- Toda alteração de fluxo crítico exige feature flag, rollback e teste de regressão.

6. Fase 0 - Alinhamento e linha de base

F0 Fundação do projeto

Semana 1

Objetivo. Definir exatamente qual versão será evoluída, como medir qualidade e como implantar sem interromper o cliente atual.

Entregas

- Confirmar repositório, branch canônica, commit e build em produção.
- Inventariar configurações do cliente atual sem copiar dados pessoais para ambientes de teste.
- Criar staging isolado, dados sintéticos e feature flags por tenant.
- Extrair 30 a 50 jornadas anonimizadas: saudação, novo cliente, agenda, confirmação, remarcação, cancelamento, pagamento, áudio e imagem.
- Definir painel mínimo de observabilidade: latência, fallback, erros, duplicidades, falha de envio e falha de sincronização.
- Registrar baseline de sete dias para comparar antes/depois.

CrITÉRIOS de aceite

- Existe uma única referência documentada para produção e desenvolvimento.
- Staging recebe webhooks de teste sem atingir pacientes reais.
- Suite inicial reproduz ao menos os erros históricos conhecidos.
- É possível desativar qualquer funcionalidade nova por tenant sem novo deploy.

Métricas-base

Métrica	Definição	Meta após F1
Taxa de erro técnico	Interações que terminam em fallback por exceção	< 0,5%
Ação incorreta	Agenda/confirm./cancel. diferente da intenção validada	0 em fluxos críticos testados
Resposta duplicada	Duas respostas para a mesma mensagem/evento	< 0,1%
Latência P95	95% das respostas abaixo do limite	< 8 s texto simples
Entrega rastreável	Mensagens com status final conhecido	> 99%

7. Fase 1 - Confiabilidade operacional

F1 Estável para operar

Semanas 2-3

Objetivo. Eliminar as falhas intermitentes que prejudicam confiança e criar garantias técnicas para agenda e mensagens.

Backlog P0 - ordem de execução

#	Implementação	Dependência	Aceite resumido
1	Corrigir duplicação da mensagem atual no histórico	F0	Cada mensagem aparece uma vez no contexto.
2	Fila e trava por tenant+telefone	1	Mensagens do mesmo contato processadas em ordem.
3	Agrupamento de mensagens por 2-4 segundos	2	Mensagens consecutivas formam uma intenção.
4	Idempotência uniforme em todos os webhooks	2	Mesmo evento nunca gera duas ações.
5	Gerador diário de slots + término no expediente	F0	Slots começam na grade configurada e não extrapolam.
6	Reserva atômica e token temporário de slot	5	Concorrência não cria choque de agenda.
7	Worker para IA e timeouts controlados	2	Webhook responde rápido e trabalho continua na fila.
8	Outbox de envio e status de entrega	4	Falha não é registrada como mensagem entregue.
9	Outbox de Google/CalDAV + reconciliação	6	Divergência aparece e é retentada.
10	Jobs com claim atômico e idempotência	8	Deploy/múltipla instância não duplica disparos.
11	SQLite WAL, busy timeout e retry curto	F0	Locks transitórios não derrubam o fluxo.
12	Logs correlacionados e alerta por severidade	2	Uma interação é rastreável de ponta a ponta.

Testes obrigatórios

- Paciente envia três mensagens rápidas; recebe uma resposta coerente.
- Dois pacientes tentam o último horário simultaneamente; apenas um agenda.
- Webhook é reenviado após timeout; nenhuma resposta ou ação é duplicada.
- Modelo demora/falha; webhook não trava e o usuário recebe fallback controlado.
- Google Calendar falha; agenda interna permanece consistente e a pendência fica visível.
- Deploy ocorre durante janela de confirmação; nenhuma mensagem é enviada duas vezes.

Saída da fase

Ao final da semana 3, o produto deve ser seguro para operar com o cliente atual, mesmo antes das novas funcionalidades de diferenciação.

8. Fase 2 - Assistente inteligente, qualidade e controle

F2 Assistente e qualidade controlável

Semana 4

Objetivo. Entregar o núcleo do assistente do profissional e transformar regras dispersas em estados, políticas, aprovações e testes.

Escopo P1

Frente	Entrega	Valor
Estado conversacional	Estados explícitos, campos coletados, faltantes e próximo passo	Menos repetição e menos dependência do histórico textual.
Decisão estruturada	Intenção, confiança, operação solicitada e handoff	A IA não afirma ação antes da ferramenta.
Chat do profissional	Perguntas naturais sobre agenda, pacientes, financeiro e pendências	Acesso rápido sem navegar por várias telas.
Ferramentas do assistente	Consultas seguras e comandos operacionais com aprovação	Ajuda prática, não apenas respostas.
Briefing inicial	Resumo do dia e itens que exigem decisão	Profissional começa o dia orientado.
Autonomia progressiva	Sugestão, assistido, autônomo e proativo por assunto	Adoção gradual e confiança.
Handoff inteligente	Deteção de sensibilidade/frustração/baixa confiança + resumo	Humano assume com contexto.
Feedback de resposta	Correta, poderia melhorar, errada + motivo	Aprendizado operacional.
Regressões automáticas	Correção aprovada vira caso de teste	Erro corrigido não retorna.
Linha do tempo	Decisão, ação, sincronização e entrega	Transparência e suporte rápido.
Modo sombra inicial	IA sugere sem enviar e compara com humano	Onboarding seguro.

Crítérios de aceite

- Toda ação crítica registra confiança, política aplicada, resultado e mensagem enviada.
- O profissional consulta agenda, confirmações, pendências e previsão sem comandos técnicos.
- Comandos de alteração mostram impacto e pedem aprovação conforme a política configurada.
- O cliente configura autonomia por categoria sem suporte técnico.
- Transferências chegam com resumo, intenção, dados relevantes e pendência exata.
- Feedback negativo cria item revisável e pode gerar teste permanente.
- Modo sombra produz relatório de cobertura e divergência antes da ativação.

9. Fase 3 - Diferenciação operacional

F3 Operação inteligente vertical

Semanas 5-6

Objetivo. Resolver tarefas que plataformas genéricas normalmente exigem configurar manualmente e tornar o produto parte da rotina diária.

Escopo P1

Módulo	Comportamento principal	Métrica de sucesso
Fila de espera	Registra preferência, encontra vaga compatível, oferece e reserva por prazo	% de cancelamentos preenchidos.
Recorrência	Cria séries semanais/quinzenais, identifica conflitos e trata exceções	% de séries sem ajuste manual.
Memória útil	Preferência de período, modalidade, frequência e nome preferido	Redução de mensagens até conclusão.
Central de pendências	Transforma conversas em tarefas priorizadas com ação rápida	Pendências resolvidas e tempo poupado.
Serviços e durações	Catálogo por tenant, preço informativo, duração e profissional	% de agendamentos autônomos.
Exceções de agenda	Feriados, férias, horários especiais e antecedência mínima	Zero oferta fora das regras.
Múltiplos profissionais	Agenda, serviço, regras e disponibilidade por profissional	Tenants aptos a ampliar equipe.
Resumo diário inicial	Agenda, não confirmados, vagas, pagamentos e contratos	Abertura/uso do briefing.

Fluxo de fila de espera - aceite mínimo

- Paciente registra interesse por dia, período, profissional e modalidade.
- Cancelamento dispara correspondência apenas para candidatos compatíveis e autorizados.
- Oferta usa reserva temporária; a vaga não é prometida simultaneamente a várias pessoas sem regra explícita.
- Ao aceitar, agenda e calendário são atualizados atômica e imediatamente; demais interessados recebem tratamento configurável.
- Profissional visualiza receita potencial recuperada.

Diferencial percebido

O cliente deixa de comprar um chatbot e passa a contratar uma operação administrativa especializada, pronta para funcionar sem desenhar fluxos técnicos.

10. Fase 4 - Inteligência e resultado

F4 Produto orientado a resultado

Semana 7

Objetivo. Usar dados operacionais para prevenir problemas, recomendar ações, recuperar receita e demonstrar retorno sobre o investimento.

Escopo P2

- Briefing diário completo: agenda, confirmações, vagas, fila de espera, contratos, comprovantes e exceções.
- Assistente responde perguntas comparativas e explica os dados usados em cada conclusão.
- Recomendações proativas priorizadas por urgência, impacto e confiança, sempre com ação sugerida.
- Prevenção de faltas baseada em sinais operacionais, nunca em diagnóstico sensível.
- Sugestão de preenchimento de buracos e melhor ordem de oferta de horários.
- Reativação assistida de clientes inativos, sempre com consentimento, frequência limitada e aprovação configurável.
- Cobrança conversacional: promessa de pagamento, divergência, pedido de total e encaminhamento humano.
- Painel de resultado com tempo poupado, faltas evitadas, vagas recuperadas e receita preservada.
- Experimentos controlados de mensagens para confirmação e preenchimento de vagas.

Indicadores principais

Indicador	Cálculo	Uso
Resolução autônoma segura	Conversas concluídas sem humano e sem correção / elegíveis	Qualidade da automação.
Mensagens até conclusão	Média por jornada concluída	Eficiência e naturalidade.
Taxa de confirmação	Consultas confirmadas / confirmações enviadas	Efetividade dos lembretes.
Taxa de falta	Faltas / consultas realizadas no período	Impacto preventivo.
Vagas recuperadas	Cancelamentos preenchidos pela fila	Receita recuperada.
Tempo administrativo poupado	Ações autônomas x tempo médio validado	ROI para o cliente.
Correções por 100 conversas	Feedbacks negativos / conversas x 100	Saúde do agente.
Handoff útil	Transferências resolvidas sem pedir contexto novamente	Qualidade da colaboração humano-IA.

11. Fase 5 - Escala, segurança e produto SaaS

F5 Pronto para crescer

Semana 8

Objetivo. Reduzir risco operacional e transformar implantação, suporte e governança em processos repetíveis.

Escopo técnico e operacional

Frente	Implementações
Banco e concorrência	Plano de migração para PostgreSQL; migrações testadas; rollback; índices e isolamento por tenant.
Filas e workers	Mensagens, jobs, sincronização e mídia fora do processo web, com retry e dead-letter queue.
Segurança de webhook	Token obrigatório para legados, validação oficial por provedor, rotação e alerta de rejeição.
Acesso	Evitar token persistente em URL, sessões seguras, expiração, revogação e perfis de permissão.
LGPD	Inventário de dados, retenção, exportação, exclusão, base legal, minimização e trilha de acesso.
Observabilidade	SLOs, alertas acionáveis, correlação, custos de IA e painel de saúde por tenant.
Onboarding	Assistente de configuração, modo sombra, checklist, teste de número e validação da agenda.
Suporte	Diagnóstico automático, pacote de evidências sem dados sensíveis e playbooks de incidente.

SLOs sugeridos para V1

Compromisso	Objetivo
Disponibilidade mensal	99,5% na V1; evoluir para 99,9% conforme receita e arquitetura.
Perda de mensagem aceita	0; toda entrada válida possui estado final rastreável.
Duplicidade de ação crítica	0; idempotência verificada por teste e métrica.
Resposta de texto P95	Até 8 segundos em condição normal.
Recuperação de job	Retry automático; alerta após limite; retomada manual segura.
RPO / RTO	RPO até 24h inicialmente; RTO até 4h, com evolução planejada.

12. Fase 6 - Piloto ampliado e lançamento

F6 Rollout da V1

Semanas 9-10

Objetivo. Validar o produto com uso real, concluir documentação e liberar comercialmente sem colocar todos os clientes em risco ao mesmo tempo.

Estratégia de liberação

Etapa	Público	Critério para avançar
Interna	Dados sintéticos e equipe	100% dos testes P0; nenhuma falha crítica aberta.
Sombra	Cliente atual, sem envio automático novo	Divergência conhecida e autonomia recomendada.
Canário	10-20% das conversas elegíveis	7 dias sem ação crítica incorreta.
Piloto	Cliente atual completo + 1 ou 2 convidados	14 dias dentro das metas operacionais.
V1	Novos clientes do segmento prioritário	Onboarding, suporte e rollback documentados.

Materiais de lançamento

- Manual curto de configuração e operação diária.
- Guia de autonomia e quando o humano assume.
- Checklist de onboarding e teste de agenda/WhatsApp.
- Política de privacidade, retenção e uso responsável de IA.
- Painel de resultado e relatório mensal compartilhável.
- Playbook de suporte, incidentes e rollback.

Definição de pronto da V1

- Nenhuma ação crítica incorreta no piloto de 14 dias.
- Erros técnicos abaixo de 0,5% e duplicidade abaixo de 0,1%.
- Cliente consegue configurar agenda, autonomia e handoff sem alteração de código.
- Resultado operacional é mensurável e compreensível no painel.
- Suporte consegue diagnosticar uma interação sem acessar conteúdo desnecessário.

13. Backlog consolidado por prioridade

A classificação usa: P0 bloqueia confiabilidade; P1 cria o núcleo do produto; P2 aumenta diferenciação/resultados; P3 é expansão posterior.

Pri.	Itens
P0	Branch/build canônica; histórico sem duplicação; fila por contato; agrupamento; dedup; slots corretos; reserva atômica; worker de IA; outbox; jobs idempotentes; logs; testes críticos.
P1	Estados; assistente do profissional; consultas naturais; ferramentas com aprovação; briefing; autonomia progressiva; handoff; feedback; regressões; fila de espera; recorrência; memória; pendências.
P2	Recomendações proativas; explicações; múltiplos profissionais; prevenção de faltas; otimização de agenda; cobrança conversacional; métricas de ROI; PostgreSQL; filas duráveis; onboarding.
P3	Multicanal; white-label; marketplace de integrações; voz/ligação; campanhas avançadas; expansão ampla de segmentos; recomendações preditivas sofisticadas.

Fora do escopo inicial

- Diagnóstico, aconselhamento clínico ou decisão médica.
- Confirmação automática de pagamento baseada apenas em imagem/comprovante.
- Campanhas massivas sem consentimento, governança e templates oficiais.
- Expansão simultânea e profunda para todos os 13 segmentos.
- Aplicativo móvel nativo antes de validar a experiência web responsiva.
- Substituição completa do atendimento humano em situações sensíveis ou ambíguas.

Segmentos recomendados

Priorizar inicialmente psicologia, nutrição e fisioterapia, que compartilham agenda recorrente, confirmação, faltas, cobrança por sessão e necessidade de comunicação cuidadosa. A expansão deve ocorrer por pacotes verticais validados, não apenas por troca de rótulos no prompt.

14. Governança e papéis

Papel	Responsabilidades
Responsável pelo produto	Prioridade, regras de negócio, validação semanal, aprovação de piloto e decisão de rollout.
Desenvolvimento	Arquitetura, implementação, testes, observabilidade, migração e documentação técnica.
Cliente-piloto	Validar linguagem, regras, exceções, feedback de respostas e impacto na rotina.
Suporte/operação	Monitorar alertas, diagnosticar falhas, executar playbooks e registrar padrões recorrentes.
Privacidade/segurança	Revisar LGPD, acessos, retenção, fornecedores, contratos e resposta a incidentes.

Ritos de governança

- Revisão semanal de produto: métricas, feedbacks, decisões e riscos.
- Revisão quinzenal de qualidade: amostra anonimizada de conversas e regressões.
- Revisão mensal de segurança, custos de IA e saúde das integrações.
- Go/no-go formal antes de aumentar a autonomia ou adicionar tenants ao piloto.

Definition of Done para cada história

- Regra de negócio e comportamento de falha documentados.
- Teste unitário e teste de jornada relevante.
- Log e métrica suficientes para diagnóstico.
- Feature flag e rollback quando houver impacto em produção.
- Interface revisada em desktop e celular quando aplicável.
- Validação em staging e piloto antes da liberação ampla.

15. Riscos e mitigação

Risco	Prob.	Impacto	Mitigação
Construir na branch errada	Alta	Crítico	F0 obrigatória; branch protegida e build identificável.
Adicionar funções antes de estabilizar	Alta	Alto	Congelar P2/P3 até critérios da F1.
Velocidade da IA reduzir revisão	Média	Crítico	Pull requests pequenos, testes, feature flags e go/no-go humano.
Cliente-piloto pouco disponível	Média	Alto	Rito semanal curto; dados anonimizados; decisões registradas.
Mudança de modelo altera comportamento	Alta	Alto	Contrato estruturado, regressões e avaliação antes do deploy.
Custos crescem com contexto/áudio	Média	Médio	Roteamento de modelos, cache, atalhos e orçamento por tenant.
Migração de banco interrompe operação	Média	Alto	Ensaio, dupla leitura quando necessário, backup e rollback.
Automação proativa gera rejeição	Média	Alto	Consentimento, frequência, horário, opt-out e piloto.
Escopo se espalha por 13 segmentos	Alta	Alto	Três verticais prioritárias e critérios de expansão.
Dependência de provedor WhatsApp	Média	Alto	Abstração, monitor, retry e plano de contingência.

Gatilhos para replanejamento

- Mais de 20% da capacidade semanal consumida por incidentes durante duas semanas.
- Falha crítica de agenda ou privacidade no piloto.
- Mudança de provedor/WhatsApp que afete templates ou webhooks.
- Necessidade de múltiplos profissionais confirmada antes da fila de espera.
- Ausência de baseline suficiente para medir benefício.

16. Próximos passos imediatos

Decisão recomendada

Iniciar a Fase 0 e não desenvolver novas funções na branch atual até confirmar a versão canônica e a build efetivamente implantada.

Primeiros 10 dias úteis

Dia	Ação	Resultado
1	Confirmar branch, commit, build e ambiente	Fonte única de verdade.
2	Mapear jornada do cliente atual e incidentes	Lista real de falhas e prioridades.
3	Criar staging e dados sintéticos	Ambiente seguro de validação.
4-5	Montar regressões de conversas	Baseline automatizado.
6	Corrigir mensagem duplicada e correlação	Contexto limpo e rastreável.
7-8	Implementar fila por contato e agrupamento	Conversas ordenadas e naturais.
9	Implementar dedup uniforme e testes	Retries não duplicam ações.
10	Piloto interno + revisão de métricas	Decisão de avançar para agenda atômica.

Decisões que o responsável pelo produto deverá validar

- Quais três segmentos serão priorizados na primeira versão comercial.
- Qual nível de autonomia será padrão para novos clientes.
- Se a fila de espera oferece a vaga para uma pessoa por vez ou para um grupo com regra de prioridade.
- Quais indicadores serão mostrados no relatório mensal de valor.
- Em que momento a migração para PostgreSQL será obrigatória por volume ou receita.

Resultado esperado

Ao final do programa, o produto deverá operar com duas inteligências integradas: um agente atende clientes com naturalidade e garantias técnicas; um assistente organiza o negócio, responde perguntas, recomenda ações e executa comandos autorizados. Ambos aprendem com correções e provam o impacto financeiro gerado. Esse conjunto - confiabilidade, especialização vertical, inteligência administrativa e resultado mensurável - constitui o diferencial competitivo central.

Documento elaborado a partir da documentação técnica e da auditoria do código disponível. Estimativas devem ser recalibradas após a Fase 0.